Step 13 broad run 결과 요약

physical_guide_flowmatching · branch claude/project-thread-43gbu8 · 2026-10-27

1. 실험 설정

- 데이터: 실제 ERA5를 5.625°로 보수적 regrid (fake data 미사용). 학습 1979–2015, 검증 2016, 테스트 2017–2018 (ClimODE와 같은 360 IC), 앙상블 8 member.
- 모델: PINN projection 8000 it (batch 8), seqfm_dct (flow matching) 40000 it (batch 16), seqregress (회귀 앙상블) 40000 it (batch 16) — GPU. Guide 적합과 채점은 CPU.
- Guide arm: regm_band = a + b·회귀 평균 + c·x(t) + FM 편차 + band Γ, regm_flow = regm_band + flow-dependent spread field, regm_flowop = regm_band + operator spread field.
- Run 종료: 2026-10-27 01:04 (본 실험 + operator ablation 모두 exit 0). 결과: runs/step13_broad/.

2. 핵심 결론

- FM + PINN + regm guide가 이번 run의 최선. z500 144h RMSE 741로 회귀 앙상블(789)과 ClimODE 논문(784)보다 낮고, z500 144h CRPS는 회귀 대비 약 8% 개선 (0.0310 vs 0.0338).
- Bootstrap 95% CI: 세 guide arm 모두 모든 변수 × 모든 lead에서 CRPS가 seqregress_pinn보다 유의하게 낮음 (차이의 CI 상한이 전부 0 미만).
- 세 arm 간 차이는 0.6% 이내. 전체 fair CRPS: band 0.1595, flow 0.1585, flowop 0.1585 — flowop은 flow 대비 이득 없음.
- Calibration: guide arm의 z500 SSR은 1.10–1.23으로 안정적 (회귀는 144h에서 1.33). 단, 여전히 약간 과분산이고 day-6 하위 tercile BSS는 -0.17.
- Flow-dependence는 약함: spread–오차 상관 band ≈ 0.01, flow 0.08–0.10, flowop 0.04–0.07.

3. 기본 모델 (guide 이전, 테스트 2017–18, z500)

모델	RMSE 24 / 144h (m²/s²)	CRPS 24 / 144h	SSR 24 / 144h	정역학 잔차
seqfm_dct raw	371 / 935	0.0176 / 0.0415	2.08 / 1.70	7.97
seqfm_dct + PINN	372 / 933	0.0176 / 0.0413	2.08 / 1.69	5.42
seqregress raw	170 / 790	0.0077 / 0.0339	1.25 / 1.34	5.22
seqregress + PINN	170 / 789	0.0077 / 0.0338	1.25 / 1.33	3.76

- FM 단독은 회귀보다 크게 나쁘고 spread가 오차의 약 2배 (SSR ≈ 2).
- PINN projection은 정확도를 거의 바꾸지 않지만 물리 잔차, 특히 정역학 잔차를 줄임 (진짜 대기 잔차 기준 ≈ 1).

4. Guide arm vs 회귀 앙상블 (테스트 2017–18)

arm	z500 RMSE 24 / 72 / 144h	t850 RMSE (K) 24 / 72 / 144h	t2m RMSE (K) 24 / 72 / 144h	z500 CRPS 24 / 72 / 144h	z500 SSR 24 / 72 / 144h
seqregress + PINN	170 / 427 / 789	1.51 / 2.26 / 3.38	1.26 / 1.79 / 2.53	0.0077 / 0.0187 / 0.0338	1.25 / 1.09 / 1.33
regm_band	170 / 423 / 741	1.49 / 2.22 / 3.21	1.25 / 1.76 / 2.38	0.0076 / 0.0183 / 0.0310	1.22 / 1.16 / 1.10
regm_flow	170 / 423 / 741	1.49 / 2.22 / 3.21	1.25 / 1.76 / 2.38	0.0076 / 0.0183 / 0.0309	1.23 / 1.17 / 1.11
regm_flowop	170 / 423 / 741	1.49 / 2.22 / 3.21	1.25 / 1.76 / 2.38	0.0076 / 0.0183 / 0.0309	1.23 / 1.16 / 1.11

- CRPS는 z500을 정규화한 값. 세 arm의 평균장은 공유되므로 RMSE가 동일.
- Bootstrap (vs seqregress_pinn) CRPS 차이의 95% CI 상한 최댓값: regm_band -4.2e-05, regm_flow -6.8e-05, regm_flowop -5.7e-05 — 모두 음수, 즉 전 변수·전 lead에서 유의한 개선.
- 작은 스케일 파워 (k13–32, 1이 완벽): z500 144h guide ≈ 5.0, 회귀 11.5. 덜 과하지만 여전히 과대.

- Doob ratio 1.00, falling steps 0 — 에너지가 lead에 따라 단조 증가 (물리적으로 일관).

5. 그림

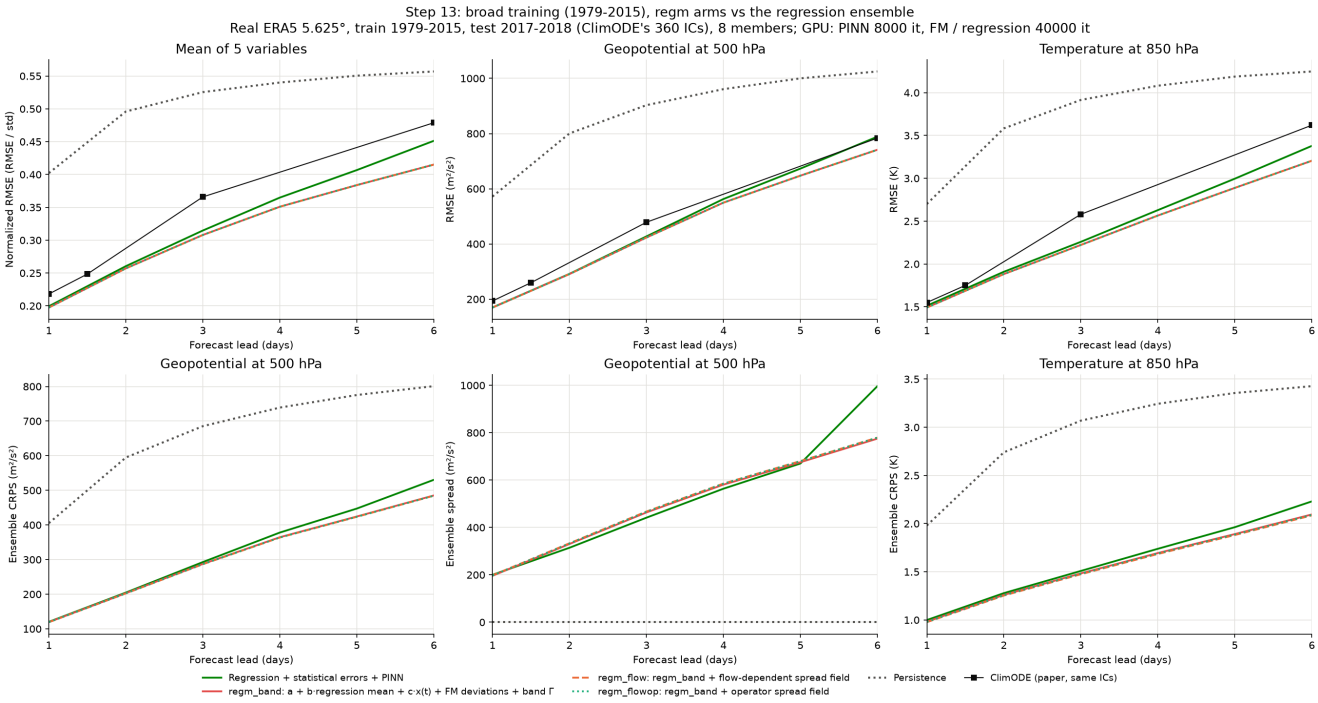


그림 1. RMSE (위)와 CRPS / spread (아래): 회귀 앙상블 (초록), regm arm 3개 (빨강/주황/청록, 거의 겹침), persistence, ClimODE 논문 값.

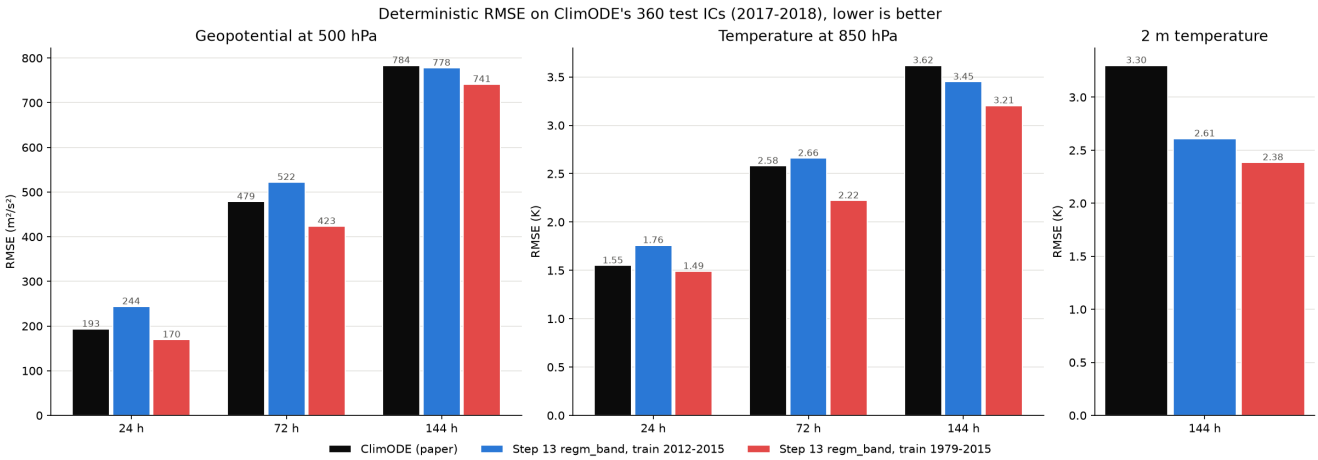


그림 2. 같은 360 테스트 IC에서의 결정론적 RMSE: ClimODE 논문, 4년 학습 (2012–2015) step 13, 이번 broad 학습 (1979–2015). 학습 기간 확장으로 모든 lead에서 개선.

6. Flow-dependence (spread가 상황별 오차를 따라가는가)

arm	spread CV	spread–|err| 상관	spread bin (하→상)	RMSE bin (하→상)
seqregress_pinn	0.27	≈ 0.00	0.64 → 1.40	1.00 → 1.00
regm_band	0.27	0.01	0.63 → 1.40	0.98 → 1.02
regm_flow	0.31–0.32	0.08–0.11	0.59 → 1.50	0.88 → 1.15
regm_flowop	0.29–0.31	0.04–0.07	0.60 → 1.46	0.92 → 1.09

- z500 / t850, 24–144h 범위 (runs/step13_broad/flowdep.log). spread가 큰 case에서 실제 오차도 큰 정도는 flow > flowop > band 순이지만 절대값은 작음.
- Guide가 예측한 σ와 |error|의 case별 상관 (z500): flow_sigma 0.15–0.18, flow_op 0.12–0.16 (2017, 2018).

7. Operator ablation (결정론적 평균, 테스트 2017–18)

평균장	z500 RMSE 24 / 72 / 144h	t850 RMSE 24 / 72 / 144h (K)
mean (seqfm_dct_pinn)	372 / 666 / 933	2.03 / 3.15 / 3.99
mbmx	333 / 631 / 863	1.92 / 3.00 / 3.72
operator	367 / 643 / 886	2.00 / 3.01 / 3.81
operator_mean_only	334 / 600 / 810	1.84 / 2.75 / 3.40
persistence	572 / 903 / 1025	2.70 / 3.91 / 4.25

- FM 앙상블 위의 operator 중 operator_mean_only가 가장 좋지만, 회귀 평균 (z500 170 / 427 / 789)보다는 단기에서 크게 뒤짐. guide arm의 평균장이 회귀 평균을 쓰는 이유.

8. 다음 단계 제안

- FM 자체의 과분산 (SSR ≈ 2)과 작은 스케일 과대 파워를 줄이는 것이 우선 — guide가 보정하는 몫을 줄임.
- flowop은 flow 대비 이득이 없으므로 단순한 regm_flow를 기본 arm으로 채택.
- Flow-dependence 강화: spread field 입력에 흐름 정보 (예: 회귀 앙상블 분산, 블로킹 지표)를 추가하는 실험.
- 하위 tercile day-6 BSS 음수의 원인 (평균 편향 vs spread) 분해.